

Hands-On Module 1 — Artificial Intelligence

Nama : Eka Suci Ramadhani

NIM : 18225063

Modul : Module 1 — Intro to AI and Python Ecosystem

Tugas : Hands-On EDA Spotify Songs Dataset

Deskripsi

Repo ini berisi pengerjaan tugas hands-on Module 1: melakukan exploratory data analysis (EDA) lengkap pada [Spotify Songs Dataset \(TidyTuesday 2020\)](https://tidytuesday.github.io/2020/07/12/tuesday-spotify-songs/) menggunakan Pandas dan NumPy.

Repository

Seluruh notebook (kode, output, dan dokumentasi lengkap) dikerjakan dan disimpan pada repository GitHub berikut:

<https://github.com/lvdis29/gdgoc/tree/f6fd7efd016c2d9ea5bbc2fa858f558db22d99e3/M1/tugas>

Cara Menjalankan

```
pip install pandas numpy jupyter
```

```
jupyter notebook spotify_eda.ipynb
```

Notebook mengambil dataset langsung dari URL TidyTuesday, jadi tidak perlu download file terpisah, cukup jalankan semua cell dari atas ke bawah.

Cerita Proses dan Eksplorasi

Awalnya aku sempat bingung mau mulai dari mana karena datasetnya lumayan besar (32 ribuan baris, 23 kolom), jadi langkah pertama yang aku lakukan adalah `df.info()` dan `df.describe()` dulu buat “kenalan” sama datanya sebelum masuk ke pertanyaan-pertanyaan analitis di instruksi tugas. Dari situ aku baru sadar ada tiga kolom dengan sedikit missing value (`track_name`, `track_artist`, `track_album_name`), tapi untungnya jumlahnya kecil banget (cuma 5 baris) jadi nggak perlu drop kolom.

Bagian yang paling bikin aku mikir agak lama justru bukan di kode-nya, tapi di keputusan strategi deduplikasi. Awalnya aku sempat coba `df.drop_duplicates()` biasa (tanpa subset), tapi ternyata jumlah baris yang kehapus sedikit banget setelah aku cek lebih teliti, ternyata itu karena satu lagu bisa muncul di banyak baris dengan `playlist_id` yang berbeda (satu lagu ada di beberapa playlist). Jadi aku ganti strateginya jadi dedup berdasarkan `track_id`, karena itu identifier resmi satu rekaman di Spotify biar statistik audio-feature nggak “dobel hitung” untuk lagu yang kebetulan masuk banyak playlist.

Waktu masuk ke bagian NumPy (normalisasi min-max dan matriks korelasi), sempat ada momen “aha” buat aku: awalnya aku kira harus loop manual per kolom buat normalisasi, tapi ternyata broadcasting NumPy bisa langsung $(X - X.min(axis=0)) / (X.max(axis=0) - X.min(axis=0))$ dalam satu baris tanpa loop sama sekali. Ini juga yang bikin aku akhirnya baca-baca lagi dokumentasi broadcasting NumPy biar paham kenapa itu bisa jalan padahal shape X dan $X.min(axis=0)$ beda.

Untuk bagian dokumentasi, aku coba pakai AI coding tool buat generate docstring, dan ternyata hasilnya nggak langsung sempurna, ada parameter yang kelewat di salah satu fungsi (feature_cols di artist_fingerprint), jadi aku harus baca ulang manual dan benerin sendiri. Ini jadi pengingat buat aku pribadi bahwa AI itu mempercepat proses nulis draft, tapi tetap harus dicek lagi teliti-teliti, apalagi kalau menyangkut detail teknis kayak signature fungsi.

Secara keseluruhan, proses ini ngebantu aku lebih paham bedanya “sekadar manggil fungsi library” dengan “benar-benar ngerti apa yang terjadi di balik layar” terutama pas harus implementasi IQR dari rumus matematikanya langsung tanpa scipy.

Ringkasan Temuan Utama

1. Genre pop punya sebaran popularitas paling lebar (variansi tertinggi di antara 6 genre) artinya label genre saja tidak cukup untuk menebak apakah pendengar akan menyukai sebuah lagu pop.
2. Jumlah lagu yang banyak tidak menjamin rata-rata popularitas tinggi, korelasi antara volume rilis dan rata-rata popularitas di antara 10 artis paling produktif sangat lemah (0.23).
3. Fitur energy berkorelasi kuat positif dengan loudness (0.68) dan kuat negatif dengan acousticness (-0.55), konsisten dengan intuisi musikal.

Evidence / Referensi

Daftar sumber dan dokumentasi yang digunakan sebagai acuan selama proses eksplorasi dan pengerjaan analisis:

1. TidyTuesday — Spotify Songs Dataset (data dictionary resmi)
<https://github.com/rfordatascience/tidytuesday/blob/main/data/2020/2020-01-21/readme.md>
2. NumPy User Guide — Broadcasting
<https://numpy.org/doc/stable/user/basics.broadcasting.html>
3. NumPy Documentation
<https://numpy.org/doc/stable/user/>
4. Pandas User Guide — Group by: split-apply-combine
https://pandas.pydata.org/docs/user_guide/groupby.html
5. Pandas User Guide — Working with missing data
https://pandas.pydata.org/docs/user_guide/missing_data.html

6. Google AI — Responsible AI Practices
<https://ai.google/responsibility/responsible-ai-practices/>
7. GitHub Copilot Documentation
<https://docs.github.com/en/copilot>
8. Gemini Code Assist Overview
<https://cloud.google.com/gemini/docs/codeassist/overview>
9. Handbook Module 1 & Hands-On Module 1 — GDGoC ITB Curriculum Team (materi kelas)