

## Hands-On Module 2 — Artificial Intelligence

Nama : Eka Suci Ramadhani

NIM : 18225063

Modul : Module 2 - Mathematical Foundation and Data Visualization for AI

Tugas : Hands-On MPG EDA

# 1. Deskripsi

Dokumen ini berisi analisis dataset MPG (fuel efficiency mobil) pakai NumPy, Pandas, Seaborn, dan Matplotlib. Tujuan tugas ini adalah nerapin konsep-konsep yang udah dipelajari di modul linear algebra (dot product, norm), statistik deskriptif, korelasi, distribusi normal, dan EDA buat ngejawab pertanyaan konkret: faktor apa aja yang paling ngaruh ke efisiensi bahan bakar mobil.

Semua perhitungan statistik dasar (mean, median, std, IQR, standardisasi z-score, correlation matrix) dikerjakan manual pakai NumPy, tanpa pakai `pandas.describe()` atau `sklearn`, sesuai requirement task specification.

# 2. Repository

Struktur file yang dikumpulkan:

|                  |                                                    |
|------------------|----------------------------------------------------|
| mpg-eda-module2/ |                                                    |
| —                | mpg_eda_module2.ipynb # notebook utama (Stage 1-4) |
| —                | evidence.pdf # dokumen ini                         |
| —                | README.md # penjelasan singkat + cara run          |

Notebook sudah dieksekusi penuh dari cell pertama sampai terakhir tanpa error (Restart & Run All), semua output dan plot udah ke-generate dan tersimpan di dalam file .ipynb-nya.

### 3. Cara Menjalankan

Langkah-langkah buat run notebook-nya dari awal:

1. Install dependency yang dibutuhkan:

```
pip install numpy pandas matplotlib seaborn jupyter
```

2. Buka notebook:

```
jupyter notebook mpg_eda_module2.ipynb
```

3. Jalankan semua cell dari atas ke bawah:

```
Kernel > Restart & Run All
```

Dataset MPG langsung di-load otomatis dari seaborn (`sns.load_dataset('mpg')`), jadi gak perlu download file terpisah cukup pastikan koneksi internet aktif pas pertama kali load.

### 4. Cerita dan Proses Eksplorasi

Pas pertama buka dataset MPG ini, aku coba cek dulu shape sama missing value-nya pakai `df.isna().sum()`. Ternyata dari 398 baris cuma kolom horsepower yang ada yang kosong, itu pun cuma 6 baris. Sempet mikir dua opsi: di-drop atau diisi pakai median. Akhirnya aku putusin buat drop aja, soalnya jumlahnya kecil banget (~1.5% dari total data) dan horsepower ini salah satu fitur numerik utama yang mau dipakai buat korelasi & regresi nanti kalau diisi pakai nilai buatan, takutnya malah bikin hasil korelasinya sedikit bias.

Bagian yang paling nge-latih logika NumPy itu pas bikin summary table manual (mean, median, std, IQR, outlier count) tanpa boleh pakai `.describe()`. Aku bikin fungsi kecil yang terima 1 array NumPy terus ngitung semuanya pakai `np.mean`, `np.median`, `np.std(ddof=1)`, sama `np.percentile` buat Q1 dan Q3. Formula outlier-nya pakai metode IQR x1.5 yang udah dijelasin di modul. Dari situ ketahuan kalau horsepower dan acceleration punya beberapa outlier awalnya sempet mikir itu data error, tapi pas dicek lagi ternyata itu emang mobil-mobil sport yang speknya jauh di atas rata-rata, jadi valid, bukan noise.


Setelah data bersih, aku extract 5 fitur numerik (mpg, displacement, horsepower, weight, acceleration) jadi satu array NumPy, terus standardisasi pakai z-score secara vectorized

(langsung operasi array, gak pakai loop). Abis itu hitung correlation matrix pakai `np.corrcoef()`. Yang paling menarik di sini adalah nemuin pola multikolinearitas displacement, horsepower, dan weight ternyata saling berkorelasi kuat banget (di atas 0.8). Ini masuk akal sih kalau dipikir-pikir: mobil bermesin besar biasanya juga lebih bertenaga dan lebih berat bodinya.

Aku juga coba jawab pertanyaan spesifik pakai boolean masking: apakah mobil dengan horsepower di atas rata-rata juga cenderung lebih berat? Ternyata iya, dan selisihnya lumayan gede. Ini jadi bukti tambahan buat pola multikolinearitas yang ketemu sebelumnya.


## 4.4 Visualisasi

Total ada 4 plot utama yang dibikin. Yang pertama histogram distribusi mpg + KDE, dikasih garis mean dan median biar kelihatan langsung skewness-nya.




*Gambar 1. Distribusi MPG (histogram + KDE) — mean > median, right-skewed*

Terus boxplot mpg per origin (USA, Europe, Japan) buat bandingin fuel efficiency antar negara asal mobil.




Gambar 2. Boxplot MPG per origin Japan paling efisien, USA paling boros

Scatter plot weight vs mpg dikasih hue berdasarkan jumlah cylinder, plus trend line manual pakai `np.polyfit()`. Dari sini kelihatan jelas pola negatif yang kuat antara weight dan mpg.




Gambar 3. Scatter weight vs mpg dengan trend line korelasi negatif kuat ( $r \approx -0.83$ )

Terakhir correlation heatmap buat ngeliat semua hubungan antar fitur sekaligus, biar pola multikolinearitas yang udah ketemu sebelumnya makin jelas kelihatan secara visual.



Gambar 4. Correlation heatmap 5 fitur numerik

Di bagian akhir aku juga bikin line chart rata-rata mpg per dekade, buat liat tren jangka panjangnya.



Gambar 5. Rata-rata MPG per dekade tren naik dari 1970-an ke 1980-an

## 4.5 Kendala dan hal yang dipelajari

Sempet agak bingung pas nentuin pasangan fitur mana yang "paling berkorelasi" secara otomatis lewat kode (bukan cuma liat manual dari tabel), akhirnya kepikiran buat masking diagonal correlation matrix jadi NaN dulu baru dicari `idxmax()`-nya, biar gak ke-detect diagonal (korelasi fitur dengan dirinya sendiri yang pasti 1.0) sebagai hasil paling tinggi. Dari proses ini jadi lebih paham kalau korelasi tinggi antar fitur input itu bukan cuma angka doang, tapi punya makna nyata (multikolinearitas) yang penting buat dipikirin kalau mau bikin model prediksi nantinya.

## 5. Ringkasan Temuan Utama

- Distribusi mpg bersifat right-skewed (mean 23.4 > median 22.75), bukan simetris ada beberapa mobil yang jauh lebih irit dari kebanyakan.
- Mobil asal Japan punya rata-rata mpg paling tinggi (paling fuel-efficient), sedangkan USA paling rendah (paling boros) dan Europe di tengah-tengah.
- Weight adalah prediktor tunggal terkuat terhadap mpg, dengan korelasi negatif sekitar -0.83 makin berat mobil, makin boros.
- Displacement, horsepower, dan weight saling berkorelasi kuat satu sama lain (semua di atas 0.8), menunjukkan multikolinearitas yang perlu diperhatikan kalau ketiganya dipakai bersamaan di model regresi.
- Mobil dengan horsepower di atas rata-rata terbukti juga cenderung lebih berat dari rata-rata dataset, memperkuat temuan multikolinearitas di atas.
- Rata-rata mpg meningkat terus dari dekade 1970-an ke 1980-an, kemungkinan besar dipengaruhi krisis minyak dunia dan regulasi efisiensi bahan bakar (seperti CAFE standard) yang mulai diberlakukan pada era tersebut.

## 6. Referensi

Essence of Linear Algebra (3Blue1Brown): <https://www.3blue1brown.com/topics/linear-algebra>

NumPy Linear Algebra Documentation:  
<https://numpy.org/doc/stable/reference/routines.linalg.html>

Seaborn Tutorial: <https://seaborn.pydata.org/tutorial.html>

Matplotlib Tutorials: <https://matplotlib.org/stable/tutorials/index.html>

Seaborn MPG Dataset (sumner data): <https://github.com/mwaskom/seaborn-data>

Statistics and Probability: <https://www.khanacademy.org/math/statistics-probability>

Seeing Theory: <https://seeing-theory.brown.edu/>